Project 1 - Piano operativo del gruppo

Documento pratico per dividere il lavoro tra tre compagni e portare il codice attuale a una soluzione riproducibile. Il piano segue il project description ufficiale: sei metodi base, analisi esplorativa, preprocessing, validazione locale, confronto dei modelli, submission e report LaTeX di massimo due pagine.

Stato di partenza del progetto

• Il caricamento corretto e': `x_train, x_test, y_train, ids_train, ids_test = load_csv_data(data)`.

• Il dataset ha 328.135 esempi di training, 109.379 di test e 321 feature dopo l'ID.

• La classe positiva e' minoritaria; il problema e' una classificazione binaria sul target MICHD.

• Il notebook contiene gia' un baseline con imputazione, rimozione delle colonne costanti, standardizzazione, split stratificato e logistic regression.

• Il parametro `sub_sample=True` riduce il training dopo il parsing, ma non evita la lettura completa dei CSV.

Regola comune

Ogni esperimento deve registrare: versione del preprocessing, modello, iperparametri, seed, numero di esempi, metrica di validation e tempo. Non si sceglie il modello usando ripetutamente il test online: il test AICrowd si usa soltanto dopo la selezione locale.

Compagno 1 - EDA e preprocessing

Obiettivo. Capire la struttura delle variabili e produrre una trasformazione riutilizzabile, senza data leakage.

Cosa fare

• Contare righe, colonne, NaN e valori distinti per ogni feature.

• Identificare feature costanti, quasi costanti, binarie, ordinali e approssimativamente continue.

• Misurare la percentuale di missing per colonna e controllare quali colonne hanno troppi valori mancanti.

• Verificare il significato dei codici speciali (per esempio 88, 99, 999) dal dizionario BRFSS prima di trasformarli.

• Creare una funzione `fit_preprocessor(x)` che calcoli statistiche solo sul fit set.

• Creare `transform(x, state)` per applicare le stesse statistiche a validation e test.

Come farlo

Per il baseline attuale: eliminare l'ID, eliminare le colonne costanti, imputare ogni colonna con la mediana del fit set e standardizzare usando media e deviazione standard del fit set. Non ricalcolare medie o mediane sul validation/test.

```
constant, medians = fit_preprocessor(x_fit)
x_fit = transform(x_fit, constant, medians)
x_val = transform(x_val, constant, medians, means, scales)
```

Output da consegnare al gruppo

• Un file `preprocessing.py` oppure funzioni nel notebook.

• Una tabella con feature eliminate e percentuali di missing.

• Due grafici utili: distribuzione del target e missingness delle feature.

• Tre varianti confrontabili: baseline, trattamento dei codici speciali, eventuale encoding selezionato.

Compagno 2 - Modelli e validazione

Obiettivo. Verificare i metodi richiesti dal corso, selezionare gli iperparametri e produrre risultati confrontabili.

Cosa fare

• Controllare le sei funzioni di `implementations.py`: GD, SGD, least squares, ridge, logistic e regularized logistic regression.

• Usare sempre vettori 1D e restituire `(w, loss)`.

• Ricordare che la logistic regression richiede target 0/1, mentre la submission richiede predizioni -1/+1.

• Confrontare almeno logistic regression e regularized logistic regression; usare ridge/least squares come baseline aggiuntivi.

• Implementare uno split stratificato fisso per gli esperimenti rapidi e almeno una validazione a piu' fold per il modello finale.

Metriche

• Accuracy da riportare, ma non usare da sola perche' la classe positiva e' rara.

• Balanced accuracy: media della recall della classe negativa e positiva.

• Confusion matrix, precision, recall e F1 della classe positiva.

Protocollo di confronto

Usare seed 42. Provare una griglia piccola e dichiarata, per esempio gamma in {0.01, 0.05, 0.1} e lambda in {1e-4, 1e-3, 1e-2, 1e-1}. Prima usare 5.000-20.000 righe per sviluppo, poi verificare il modello scelto sul training completo. Registrare anche il tempo.

La tabella minima deve contenere: modello, preprocessing, gamma, lambda, iterazioni, balanced accuracy, F1, tempo e osservazioni.

Compagno 3 - Pipeline finale e report

Obiettivo. Integrare il lavoro, garantire la riproducibilita' e scrivere il report finale.

Cosa fare

• Mantenere `run.ipynb` come entry point eseguibile dall'inizio alla fine.

• Creare una cache locale `.npz` per gli esperimenti subsampled, senza includerla necessariamente nel repository.

• Salvare nel notebook il seed, il preprocessing, gli iperparametri e il nome esatto del file di submission.

• Allenare il modello finale solo dopo la selezione tramite validation/cross-validation.

• Controllare che il file abbia esattamente le colonne `Id,Prediction`, stesso numero di righe del test e predizioni solo -1/+1.

Struttura del report di due pagine

• Introduzione e descrizione del problema: circa 1 paragrafo.

• Preprocessing e modelli: metodo abbastanza dettagliato da essere riprodotto.

• Risultati: tabella baseline e ablation study.

• Discussione: effetto dello sbilanciamento, missingness e regolarizzazione.

• Conclusione: modello scelto, metriche locali e risultato della submission.

Controlli finali

• Il codice non importa pandas, sklearn o altre librerie ML esterne.

• Le sei funzioni richieste restano presenti in implementations.py.

• Il notebook funziona con kernel pulito e Restart & Run All.

• La submission finale e' generata dal codice, non caricata manualmente.

Coordinamento e calendario operativo

Fase	Responsabile	Risultato
1. Baseline funzionante	Tutti	Notebook che carica dati e produce un file valido.
2. EDA e preprocessing	Compagno 1	Funzioni e tabella delle trasformazioni.
3. Modelli e tuning	Compagno 2	Tabella validation e modello selezionato.
4. Integrazione	Compagno 3	run.ipynb completo e submission riproducibile.
5. Report e controllo	Tutti, coordinatore 3	PDF LaTeX, README e verifica finale.

Checklist prima della consegna

- README con istruzioni per ambiente, esecuzione e struttura dei file.
- run.ipynb eseguibile senza modifiche manuali.
- implementations.py conforme alle firme richieste.
- Preprocessing descritto nel report e nel codice.
- Validation locale separata dal test AICrowd.
- Ablation study con differenze quantitative.
- PDF del report entro due pagine, riferimenti eventualmente a pagina tre.